Structures de fichiers (SFSD)

Introduction aux Bases de Données

- opérations sur les fichiers -

École nationale Supérieure d'Informatique (ESI)

Notions de Bases de données

- SGBD (Système de Gestion de Bases de Données)
 - « grand » volume de données liées entre elles (= structure)
 - ensemble de programmes qui gèrent ces données (= traitement)
- Objectifs
 - efficacité (très important)
 - sécurité
 - facilité d'utilisation

Intérêts des SGBD

- Redondance et inconsistance des données
 - certaines info se trouvent sur plusieurs fichiers
- Difficulté d'accès aux informations non prévues
 - nécessité d'écrire de nouveaux prog. d'accès
- Dépendance : rep. interne / Applications
 - changement de structure -> re-programmation des App
- Atomicité et pb de concurrence
 - erreur, pannes, accès concurrents -> introduisent des inconsistances

Modèles de données

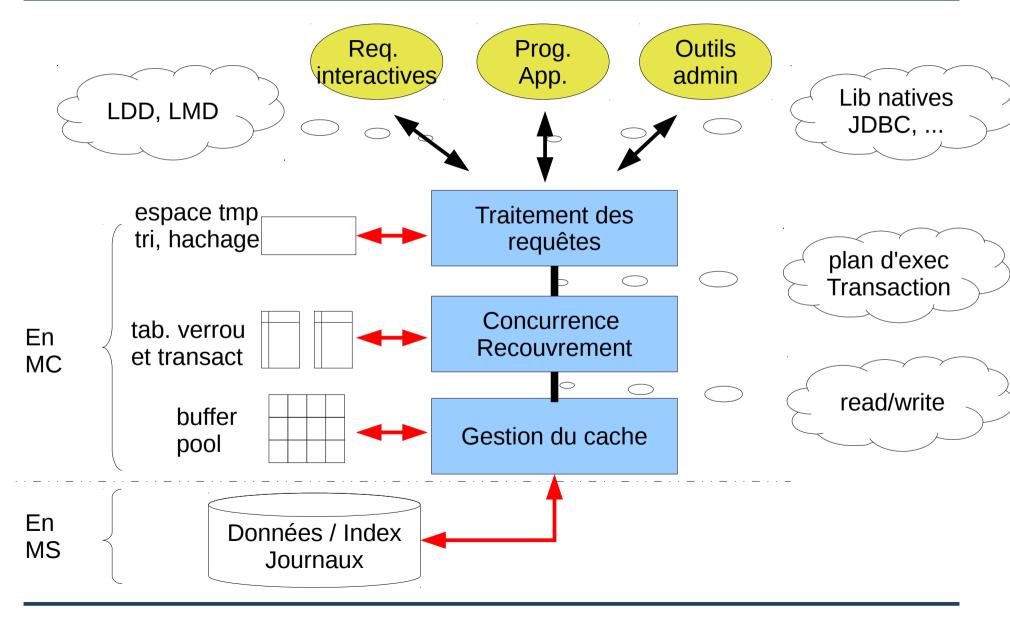
Définition

Outils conceptuels pour décrire les données, les liens, la sémantique et les contraintes.

• Exemples de modèles

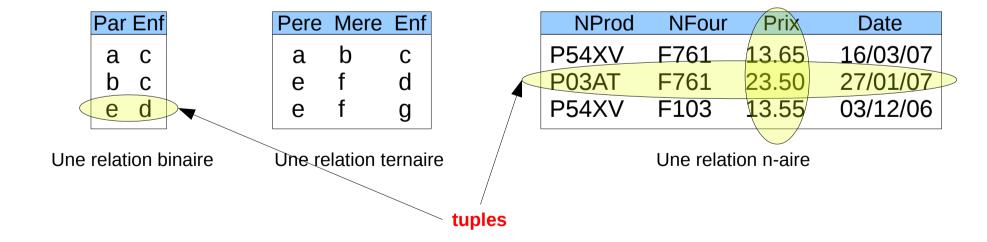
- Le modèle Entités-Associations
- Le modèle Relationnel
- Le modèle Objet
 - Le modèle Relationnel-Objet
- Anciens modèles:
 - Hiérarchique, Réseau (CODASYL)

Architecture du SGBD



Le modèle relationnel

- BD = ensemble de tables (des fichiers)
- Table T(A1:D1, A2:D2, ... An:Dn)
 - sous-ens du produit cartésien des domaines de ses constituants. T ⊆ {D1xD2x...Dn}
 - Une table est donc une Relation

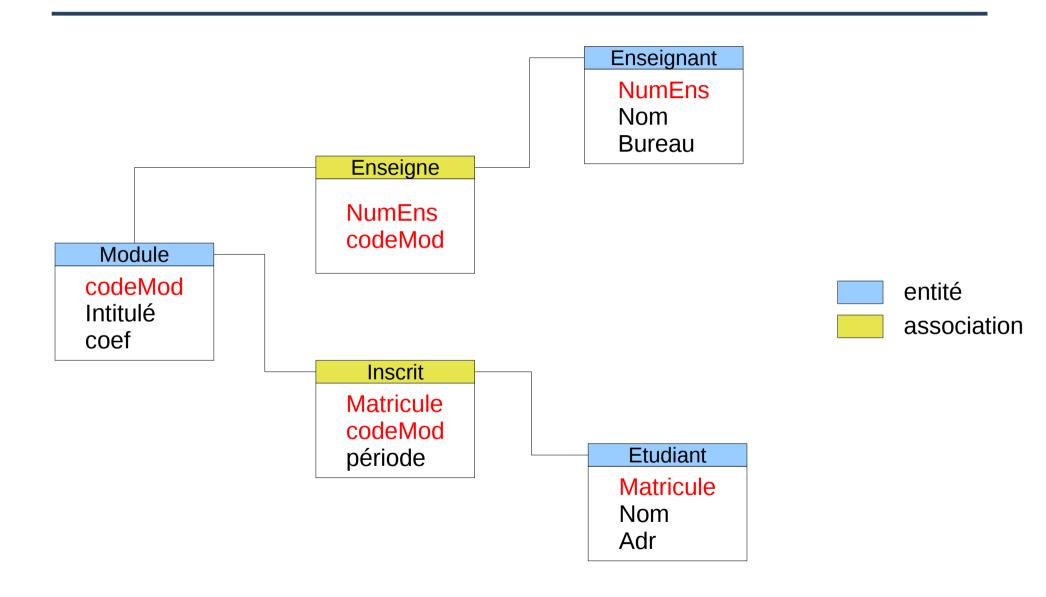


Conception de schémas

- Il y a des tables qui représentent des entités avec leurs propriétés
 - Patient(<u>NumP</u>, Nom, Adr)
 - Pathologie(<u>cod</u>e, description)
- Il y a des tables qui représentent des associations entre entités
 - Malade(<u>NumP, code</u>, date)

Cette relation **associe** un patient (NumP) avec une pathologie (code)

Exemple



Algèbre relationnelle

- Langage de requêtes procédural
 - On doit spécifier comment trouver le résultat
- Chaque opération a 1 ou 2 relations en entrée et 1 relation en sortie

 Une requête est une expression (composition) d'opérations algébriques

Quelques opérateurs relationnels

opérateurs unaires

- Sélection ou Restriction
 σ (cond / R)
- Projection

 Π (liste_attr / R)

Renommage

r (R1 / R2)

opérateurs binaires

• Union

 $R1 \cup R2$

Différence

R1 - R2

Produit cartésien

R1 x R2

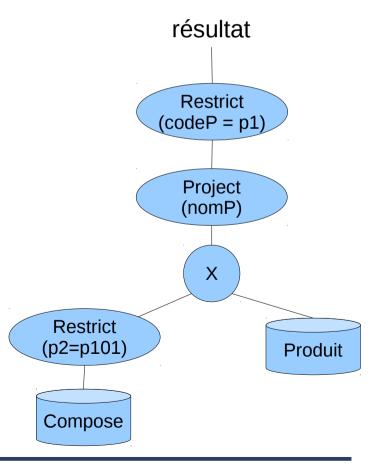
Exemple de requêtes

Soient 2 tables relationnelles

- Produit(codeP, NomP, description)
- Compose(p1, p2, qte)
 // le produit 'p1' est composé de 'qte' sous-prod 'p2'

Donner le nom des produits composés par le sous-produit de code 'P101'

R1 =
$$\sigma$$
 (p2='P101' / Compose)
R2 = Produit σ R1
R3 = σ (codeP=p1 / R2)
Résultat = σ (NomP / R3)



Autres opérateurs algébriques

• Intersection (R et S de même schéma)

$$R \cap S = R - (R - S)$$

• Jointures (naturelle - cnd implicite, théta - cnd explicite)

$$R \otimes_{(cnd)} S = \sigma (cnd / R \times S)$$

• Division (schéma de S ⊂ dans schéma de R)

```
\begin{split} R_{(a1,a2,...b1,b2,...)} &\div S_{(b1,b2,...)} = T_{(a1,a2,...)} \\ &= \prod (a1,a2,.../R) - \prod (a1,a2,.../(\prod (a1,a2,.../R) \times S) - R)) \\ &\text{un tuple t est dans T ssi} \end{split}
```

- t est dans $\prod (a_1, a_2, ..., R)$ et,
- pour chaque tuple ts dans S, il existe un tuple tr dans R :
 tr[b1,b2,...] = ts et tr[a1,a2,...] = t

Le langage SQL

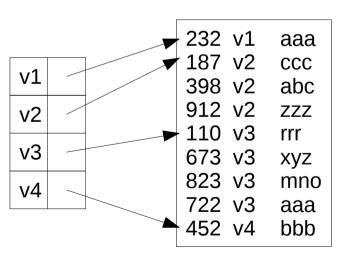
```
SELECT exp1, exp2, ...
  FROM R1, R2, ...
  WHERE <Cond>
= \Pi(\exp 1, \exp 2, \dots / \sigma (\operatorname{Cond} / \operatorname{R1} \times \operatorname{R2} \times \dots))
Exemples:
SELECT NomP FROM Produit WHERE codeP='P653';
SELECT NomP, qte
  FROM Produit, Compose
  WHERE codeP=P2 AND P1='P326';
```

Stockage

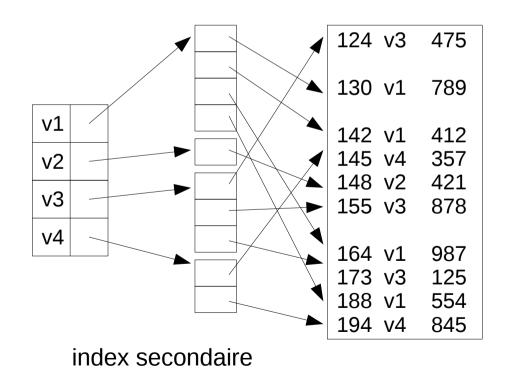
- Fichier = ensemble de blocs d'enregistrements
- un enregistrement peut être de taille fixe ou variable (longueur de champs, nombre de champs)
- organisation de fichier
 - non ordonné (heap file)
 - ordonné (sur un ou + attributs) : fichier séquentiel
- Clustering
 - rassembler dans le même bloc, les enreg susceptibles d'être traités ensembles.

Index

- structuré en tables ou arbres (B-Arbres)
- Primaire (dense ou non dense)
 si le fichier est ordonné suivant l'attribut indexé
- Secondaire (dense) si le fichier n'est pas ordonné

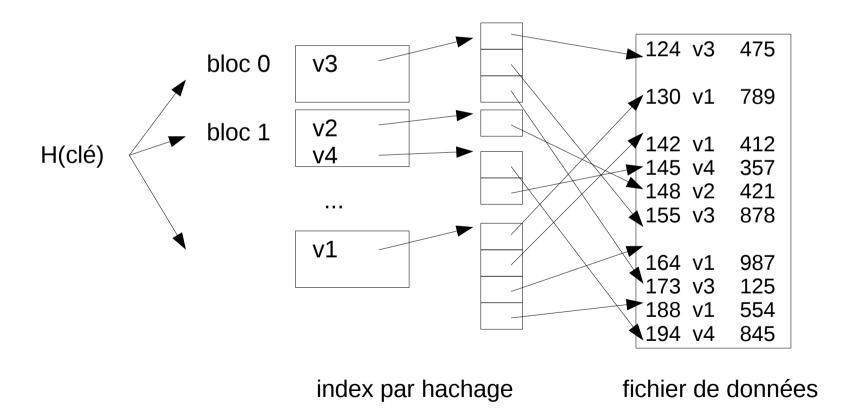


index primaire dense (contient toutes les valeurs)



Hachage

• On peut construire une table de hachage jouant le rôle d'index sur un fichier de données existant



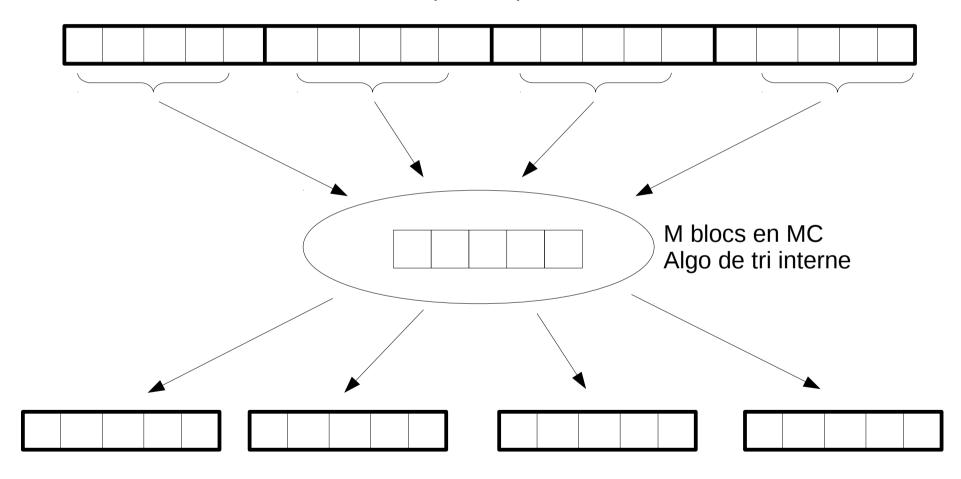
Implémentation des Opérateurs

- Sélection (avec et sans index)
- Tri « par fusion » (en 2 phases)
- Jointure
 - boucles imbriquées
 - « par fusion »
 - « par hachage »
- Autres opérateurs (intersection, différence, ...)
 - Utilisent des algorithmes similaires à ceux de la jointure

Tri par fusion (externe)

- première phase -

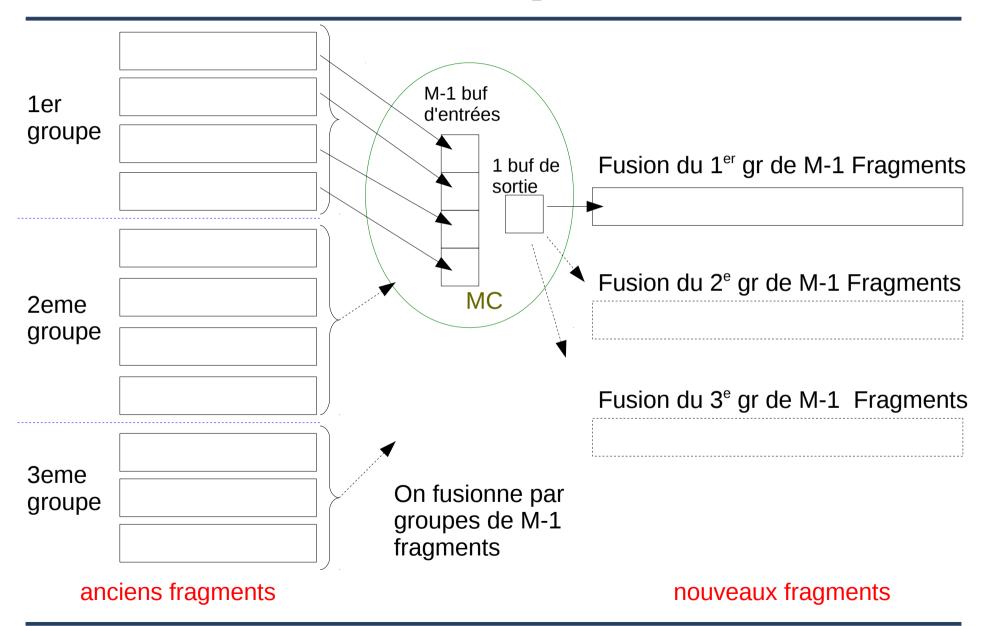
Fichier initial (non trié) de taille N blocs



[N/M] Fragments initiaux triés, de taille M blocs chacun

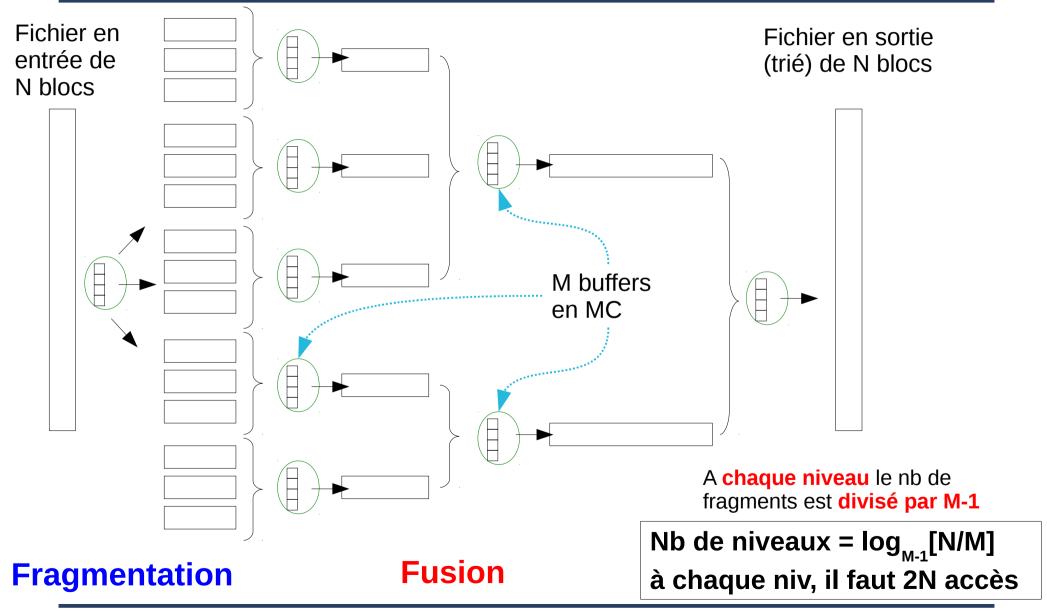
Tri par fusion (externe)

- Deuxième phase -



Tri par fusion (externe)

- Schéma général -



Jointure par boucles imbriquées

R (Relation externe : ${\tt N_{\scriptscriptstyle R}}$ blocs) x S (Relation interne : ${\tt N_{\scriptscriptstyle S}}$ blocs)

- Utiliser le max d'espace mémoire pour la relation externe (la plus petite)
 M-2 buffers pour R, 1 buffer pour S et 1 buffer pour écrire le résultat.
- Lire R par fragments de M-2 blocs. Pour chaque fragment de R, lire S

Pour chaque **fragment Fr** de **R** (lecture de M-2 blocs de **R**)

Pour chaque **bloc Bs** de **S** (lecture d'un bloc de **S**)

Pour chaque tuple tr dans Fr

Pour chaque tuple ts dans Bs

Si la condition de jointure est vérifiée entre tr et ts rajouter la concaténation tr.ts au résultats B Si B est plein, le vider sur disque

• Coût de l'opération (sans compter l'écriture du résultat) :

S est lue $[N_R/(M-2)]$ fois. **R** est lue une seule fois

$$= N_R + N_S [N_R/(M-2)]$$
 accès disque